

***Universidad Tecnológica
de El Salvador***



Facultad de Informática y Ciencias Aplicadas

Escuela de Informática

Asignatura: Técnicas de Producción Industrial de Software II

Sección: 01

Docente: Jorge Edwin Machado Leiva

Actividad: Caso Práctico Aplicado

Alumna: Katia Elizabeth Musun Duque

San Salvador 11 de mayo de 2026

Introducción al caso

En unas organizaciones dedicadas al desarrollo de software, el análisis de datos ayuda a tomar decisiones sobre contratación, formación y valoración de perfiles profesionales. Comprender la relación entre variables como educación, ingresos y prestigio ocupacional permite identificar patrones útiles para la gestión del talento.

En este caso práctico se utilizó el dataset *Prestige_modificado.csv* para aplicar técnicas de correlación y clusterización K-Means en Python. El propósito fue analizar relaciones entre ocupaciones y generar conclusiones aplicadas al contexto de producción industrial de software en la empresa InnovaSoft Analytics.

Objetivo del análisis

Objetivo general

Aplicar técnicas de análisis de datos en Python para identificar relaciones y agrupaciones entre ocupaciones y variables socioeconómicas relevantes.

Objetivos específicos

- Preparar y validar el dataset antes del análisis.
- Identificar variables relacionadas con el prestigio ocupacional.
- Construir matrices de correlación e interpretar resultados.
- Aplicar clusterización K-Means con 4 y 5 grupos.
- Comparar ambos modelos de agrupación.

- Relacionar los hallazgos con decisiones dentro de una organización de software.

Descripción del dataset

Campo	Descripción
Occupation	Nombre de la ocupación o rol analizado.
Education	Nivel educativo promedio asociado a la ocupación. A mayor valor, mayor nivel educativo.
Income	Ingreso promedio asociado a la ocupación.
Women	Porcentaje de mujeres en la ocupación.
Prestige	Nivel de prestigio o valoración social de la ocupación.
Census	Código ocupacional utilizado como identificador de referencia.
Type	Tipo de ocupación codificado numéricamente: 0 no aplicable, 1 profesional/técnica/gerencial, 2 blue collar, 3 white collar.

Preparación de datos en Python.

Librerías necesarias

```
import pandas as pd
```

carga de archivos csv

```
url = 'https://raw.githubusercontent.com/KatiaMusun/Caso_pr-ctico_aplicado/refs/heads/main/Archivos/Prestige_modificado.csv'
df=pd.read_csv(url,sep=',')
df.head()
```

	occupation	education	income	women	prestige	census	type_num
0	gov.administrators	13.11	12351	11.16	68.8	1113	1
1	general.managers	12.26	25879	4.02	69.1	1130	1
2	accountants	12.77	9271	15.70	63.4	1171	1
3	purchasing.officers	11.42	8865	9.11	56.8	1175	1
4	chemists	14.62	8403	11.68	73.5	2111	1

Revisión inicial del dataset

```
print(df.shape)

... (102, 7)
```

Revisión de tipos de datos

```
print(df.info())
```

```
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 102 entries, 0 to 101  
Data columns (total 7 columns):  
#   Column      Non-Null Count  Dtype  
---  -  
0   occupation  102 non-null    object  
1   education   102 non-null    float64  
2   income      102 non-null    int64  
3   women       102 non-null    float64  
4   prestige    102 non-null    float64  
5   census      102 non-null    int64  
6   type_num    102 non-null    int64  
dtypes: float64(3), int64(3), object(1)  
memory usage: 5.7+ KB  
None
```

Revisión de valores nulos

```
print(df.isnull().sum())
```

```
occupation    0  
education     0  
income        0  
women         0  
prestige      0  
census        0  
type_num      0  
dtype: int64
```

Revisión de registros duplicados

```
print(df.duplicated().sum())
```

```
0
```

Estadística descriptiva

```
print(df.describe())
```

	education	income	women	prestige	census	\
count	102.000000	102.000000	102.000000	102.000000	102.000000	
mean	10.738039	6797.901961	28.979020	46.833333	5401.774510	
std	2.728444	4245.922227	31.724931	17.204486	2644.993215	
min	6.380000	611.000000	0.000000	14.800000	1113.000000	
25%	8.445000	4106.000000	3.592500	35.225000	3120.500000	
50%	10.540000	5930.500000	13.600000	43.600000	5135.000000	
75%	12.647500	8187.250000	52.202500	59.275000	8312.500000	
max	15.970000	25879.000000	97.510000	87.200000	9517.000000	

	type_num
count	102.000000
mean	1.843137
std	0.817447
min	0.000000
25%	1.000000
50%	2.000000
75%	2.000000
max	3.000000

Análisis de correlación e interpretación.

Se pretende identificar qué variables tienen mayor relación con el prestigio ocupacional, se debe calcular una matriz de correlación y analizar especialmente la variable Prestige.

```
variables_numericas = df.select_dtypes(include=['int64', 'float64'])
matriz_correlacion = variables_numericas.corr()

print(matriz_correlacion.round(3))
print("-" * 60)
print(matriz_correlacion['prestige'].sort_values(ascending=False).round(3))
```

	education	income	women	prestige	census	type_num
education	1.000	0.578	0.062	0.850	-0.823	-0.382
income	0.578	1.000	-0.441	0.715	-0.361	-0.368
women	0.062	-0.441	1.000	-0.118	-0.227	0.251
prestige	0.850	0.715	-0.118	1.000	-0.635	-0.465
census	-0.823	-0.361	-0.227	-0.635	1.000	0.288
type_num	-0.382	-0.368	0.251	-0.465	0.288	1.000

```
prestige    1.000
education   0.850
income      0.715
women       -0.118
type_num    -0.465
census      -0.635
Name: prestige, dtype: float64
```

Prestigio - educación

0.850

Las ocupaciones con mayor nivel educativo tienden a tener mayor prestigio social. Este resultado es coherente porque profesiones técnicas y gerenciales suelen requerir formación avanzada.

Prestigio - income

0.715

Las ocupaciones mejor remuneradas suelen percibirse como más prestigiosas. Sin embargo, esto no significa que el ingreso cause directamente prestigio.

Prestigio - women

-0.118

Existe una relación negativa débil, esto significa que algunas ocupaciones con mayor porcentaje de mujeres tienden a mostrar niveles de prestigio menores dentro del dataset analizado. Este resultado no implica inferioridad profesional, el prestigio ocupacional puede estar influenciado por desigualdades del mercado laboral. Desde el contexto de software, este resultado puede ayudar a detectar posibles brechas de valoración entre distintos perfiles laborales y reforzar políticas de inclusión y equidad.

Prestigio - Census:

-0.635

Se encuentra una relación negativa considerable. Census funciona principalmente como un código identificador ocupacional y no como una característica socioeconómica directamente relacionada con el prestigio, por esto la correlación considerable entre Census y Prestige es coherente y esperada.

Prestigio- type_num:

-0.465

Se encuentra una correlación negativa débil entre prestigio y type num. La variable Type sí aporta información útil para explicar diferencias en prestigio ocupacional, aunque no con la misma fuerza que Education o Income.


Visualización de resultados

```
import matplotlib.pyplot as plt


plt.figure()
plt.scatter(df['education'], df['prestige'])
plt.xlabel('Education')
plt.ylabel('Prestige')
plt.title('Relación entre educación y prestigio')
plt.show()

plt.figure()
plt.scatter(df['income'], df['prestige'])
plt.xlabel('Income')
plt.ylabel('Prestige')
plt.title('Relación entre ingreso y prestigio')
plt.show()
```

Como se puede apreciar en la gráfica a mientras mayor es el nivel educativo el nivel de prestigio tiende a ser más alto



Como se puede observar en la gráfica mayor ingreso tiene la profesión el nivel de prestigio también tiende a ser más alto.



Análisis de agrupación con K-Means.

se aplicará clusterización para identificar grupos de ocupaciones con características similares. Se deben construir al menos dos modelos: uno con 4 grupos y otro con 5 grupos, y luego justificar cuál considera más útil para interpretar el caso.

Escalar los datos antes de aplicar K-Means.

Ejecutar K-Means con 4 clústeres.

Ejecutar K-Means con 5 clústeres.

```

from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans

columnas_cluster = ['education', 'income', 'women', 'prestige', 'type_num']
X = df[columnas_cluster].copy()

escalador = StandardScaler()
X_escalado = escalador.fit_transform(X)

modelo_k4 = KMeans(n_clusters=4, random_state=42, n_init=10)
df['Cluster_4'] = modelo_k4.fit_predict(X_escalado)

modelo_k5 = KMeans(n_clusters=5, random_state=42, n_init=10)
df['Cluster_5'] = modelo_k5.fit_predict(X_escalado)

print(df.groupby('Cluster_4')[columnas_cluster].mean().round(2))
print(df.groupby('Cluster_5')[columnas_cluster].mean().round(2))

```

El escalamiento fue necesario porque las variables tienen diferentes rangos y K-Means trabaja utilizando distancias.

Comparar los centroides de ambos modelos.

	education	income	women	prestige	type_num
Cluster_4					
0	13.59	7329.35	36.35	63.33	0.95
1	8.82	5878.74	9.60	37.26	2.09
2	10.12	3545.04	74.16	37.76	2.57
3	14.69	15746.83	6.00	74.23	1.00
	education	income	women	prestige	type_num
Cluster_5					
0	10.94	3909.12	73.76	41.50	2.88
1	9.31	6922.03	5.84	42.18	2.25
2	13.59	7329.35	36.35	63.33	0.95
3	7.78	3327.48	34.10	26.87	1.71
4	14.69	15746.83	6.00	74.23	1.00

El modelo de 4 clúster ofrece una interpretación más clara y general.

Interpretar qué caracteriza a cada grupo

Modelo con 4 clusters

Cluster 0: Educación alta, ingreso medio-alto, prestigio medio-alto, participación femenina moderada. Profesiones técnicas/administrativas con buen reconocimiento.

Cluster 1: Educación baja-media, ingreso medio, prestigio bajo, muy baja participación femenina. Ocupaciones masculinizadas, de menor prestigio.

Cluster 2: Educación media, ingreso bajo, prestigio bajo, alta participación femenina. Ocupaciones feminizadas, con menor valoración social.

Cluster 3: Educación muy alta, ingreso muy alto, prestigio muy alto, baja participación femenina. Profesiones de alto rango

Modelo con 5 clusters

Cluster 0: Educación media, ingreso bajo, prestigio bajo-medio, alta participación femenina. Ocupaciones feminizadas de baja remuneración.

Cluster 1: Educación baja-media, ingreso medio, prestigio bajo-medio, muy baja participación femenina. Oficios masculinizados con ingresos moderados.

Cluster 2: Educación alta, ingreso medio-alto, prestigio medio-alto, participación femenina moderada. Profesiones técnicas/administrativas.

Cluster 3: Educación baja, ingreso bajo, prestigio muy bajo, participación femenina moderada. Ocupaciones marginales, poco reconocidas.

Cluster 4: Educación muy alta, ingreso muy alto, prestigio muy alto, baja participación femenina. Profesiones de alto rango.

Identificar cuáles grupos tienden a tener mayor prestigio y cuál menor prestigio.

Mayor prestigio:

Cluster 3 (modelo 4) y Cluster 4 (modelo 5): Profesiones de alto grado.

Cluster 0 (modelo 4) y Cluster 2 (modelo 5): Profesiones técnicas/administrativas con prestigio medio-alto.

Menor prestigio:

Cluster 1 y 2 (modelo 4): Ocupaciones masculinizadas de bajo prestigio y ocupaciones feminizadas de bajo ingreso.

Cluster 3 (modelo 5): Ocupaciones marginales con prestigio muy bajo.

Cluster 0 (modelo 5): Ocupaciones feminizadas de baja remuneración.

Justificación

El modelo de 4 clusters es más clara y general además de más fácil de interpretar se puede distinguir claramente entre ocupaciones de alto rango, técnicas, masculinizadas de bajo prestigio y feminizadas de bajo ingreso.

Hallazgos principales.

Interpretación orientada a producción industrial de software

¿Qué variables parecen tener mayor relación con el prestigio de una ocupación?

Educación e income presentan las relaciones más altas con prestigio, a mayor nivel educativo promedio, tienden a haber mayor prestigio. Esto refleja que la especialización y la formación avanzada son factores clave para la valoración social y profesional.

¿Cómo podría una empresa de software usar este tipo de análisis para valorar roles técnicos, gerenciales o de soporte?

Este análisis podría ayudar a identificar perfiles de alto valor detectar las brechas de salariales entre roles, clasificación de perfiles técnicos, administrativos y operativos además de optimizar procesos de contratación y desarrollo profesional.

Los roles técnicos: deben recibir inversión en formación continua y salarios competitivos.

Roles gerenciales: requieren programas de liderazgo y gestión de proyectos.

Roles de soporte: Se recomienda capacitación, automatización y redefinición de funciones para elevar su valor.

¿Qué grupos de ocupaciones se identificaron y cómo podrían interpretarse?

Se identificaron grupos con profesionales de elite: alta educación, altos ingresos, prestigio alto,

técnicos especializados: educación media-alta, ingresos medios, prestigio medio.

Roles feminizados de soporte: ingresos bajos, prestigio bajo, alta participación femenina.

Roles masculinizados de baja valoración: ingresos moderados, prestigio bajo.

¿Existen resultados que parezcan anómalos o difíciles de explicar?

Sí. Algunas ocupaciones muestran un alto ingreso, pero prestigio moderado mientras que otras presentan alto porcentaje de mujeres y prestigio menor. Además de educación alta sin ingresos proporcionalmente altos. Estos resultados reflejan sesgo social más que lógica técnica.

¿Qué información adicional haría falta para tomar mejores decisiones?

Experiencia laboral, certificados profesionales, región geográfica, productividad y demanda del mercado.

El prestigio en software se construye principalmente sobre educación y remuneración, mientras que la participación femenina revela una brecha de valoración que debe atenderse.

El análisis permite redefinir perfiles y procesos para equilibrar la valoración de roles. Los clusters reflejan la estratificación interna de roles en la producción de software. Existen sesgos estructurales que deben corregirse con políticas de equidad y comunicación interna.

Se requiere información complementaria para decisiones más precisas sobre formación, especialización y mejora de procesos.

Conclusiones y recomendaciones.

Los hallazgos principales muestran que educación y remuneración están relacionados con el prestigio, mientras que la brecha de género y la invisibilidad de ciertos roles de soporte son retos estratégicos. La empresa InnovaSoft Analytics debería usar estos resultados para invertir en formación avanzada, equilibrar la valoración de roles, automatizar procesos de soporte y reforzar políticas de inclusión.

Url del repositorio de github

https://github.com/KatiaMusun/Caso_pr-ctico_aplicado.git